

SITP BOGOTÁ

Patrones de uso del SITP en Bogotá

Análisis exploratorio, estadístico y segmentación de estaciones

Nicolás Rincón • Felipe Mesa • Juan Benavides • Thomas Serna

Facultad de Ingeniería, Universidad EAN — Ingeniería de Sistemas, Data Xperience

13 de septiembre de 2026

Un vistazo a los hallazgos principales

1.047.338

Registros depurados
(de 1.048.575 iniciales)

62.331

Validaciones en Portal Américas,
la estación líder

06:00

Hora de mayor concentración
(201.873 validaciones)

70,47%

De las validaciones se hicieron
con tulla Plus

K = 2

Grupos de estaciones identificados
(silueta 0,4009)

76,24%

Varianza explicada por PCA
en 2 componentes

¿Cómo identificar patrones de uso del SITP?

Pregunta principal

¿Cómo puede la depuración y el análisis básico de los registros de uso del SITP permitir identificar patrones según estación, tipo de tarjeta y perfil del usuario?

Objetivo general

Analizar y depurar registros de validación para identificar patrones de estación, horario, tarjeta y perfil, y segmentar estaciones mediante un modelo no supervisado.

Cinco preguntas orientadoras

- 1 ¿Qué estaciones tienen mayor volumen?
- 2 ¿En qué horarios se concentra la actividad?
- 3 ¿Qué tipo de tarjeta se usa más?
- 4 ¿Qué perfil de usuario predomina?
- 5 ¿Hay diferencias entre estación y horario?

Validaciones Diarias SITP: origen y estructura

Fuente institucional: Datos Abiertos Bogotá, conjunto distribuido por TransMilenio S.A., licencia Creative Commons Attribution 4.0.

Contenido: variables de acceso, día, dispositivo, estación/parada, hora, tarjeta, perfil, tarifa y valor de la transacción, entre otras.

22

columnas iniciales

19

columnas finales
(útiles para el análisis)

1.048.575 → 1.047.338 registros

Variables eliminadas por estar 100% vacías: ID_Vehiculo, Ruta y Tipo_Vehiculo

La reducción de registros equivale a solo ~0,118% del total inicial: se corrigen problemas de calidad sin perder volumen relevante de información.


Control de calidad antes y después de la depuración

Indicador	Antes	Después	Cambio
Registros	1.048.575	1.047.338	-1.237
Columnas	22	19	-3
Duplicados	1.237	0	-1.237
Columnas 100% vacías	3	0	-3

Proceso aplicado

- Carga del CSV con pandas (separador ;)
- Normalización de nombres de columnas
- Eliminación de 3 columnas vacías
- drop_duplicates() sobre registros
- Estandarización de cadenas de texto
- Conversión de Valor a tipo numérico



Las estaciones con mayor número de validaciones



Portal Américas lidera con 62.331 validaciones (5,95% del total), seguido de Portal Sur JFK Cooperativa Financiera (48.590) y Portal Suba (45.525).

La demanda no se distribuye de forma uniforme entre estaciones: las validaciones reflejan concentración, no necesariamente el número único de personas.

La actividad se concentra en la madrugada y la mañana




06:00

Hora con mayor conteo:
201.873 validaciones


Mañana (06-11)	725.216	69,24%
Madrugada (00-05)	164.027	15,66%
Tarde (12-17)	158.094	15,09%
Noche (18-23)	0	0%

La franja Noche no registra validaciones: es una limitación del dataset, no evidencia de que el SITP deje de operar.


Tipo de tarjeta y perfil de usuario



tullave Plus concentra 70,47% de las validaciones (738.065) frente a 29,53% de tullave Básica. • **Adulto** es el perfil dominante con 50,08% (524.518), seguido de Anonymous (29,53%) y Adulto Mayor (8,95%).



La tarifa (Valor) es una variable discreta y concentrada



Q1 = Q3 = \$3.550: el rango intercuartílico es cero.

Bajo la regla de Tukey, 177.985 registros quedan marcados como "atípicos" — pero no son errores: reflejan una tarifa altamente concentrada en \$3.550, con una masa relevante de valores inferiores (transbordos, subsidios).

No deben eliminarse estos registros solo por la etiqueta estadística de outlier.

Estadístico	Resultado
Media	2.946,71
Mediana	3.550
Desv. estándar	1.333,31
Q1 / Q3	3.550 / 3.550
Asimetría	-1,758

Asociación entre variables categóricas (chi-cuadrado)

Comparación	χ^2	gl	p	Cramér V
Tarjeta × Perfil	1.047.337	6	< ,001	1,00
Tarjeta × Franja horaria	1.019,67	2	< ,001	0,031
Estación (top 10) × Franja	12.286,62	18	< ,001	0,077


Significancia estadística ≠ magnitud práctica

Con más de un millón de registros, casi cualquier asociación resulta "significativa" en sentido estricto. Cramér V muestra que tarjeta-franja y estación-franja tienen un efecto pequeño, mientras que tarjeta-perfil es extremadamente fuerte, lo que sugiere que ambas variables están casi determinadas por el tipo de registro del usuario.

Perfil horario de las diez estaciones principales

Sin variable de zona

Las 19 columnas disponibles no incluyen una variable geográfica; el análisis se limita a estación y horario, sin inventar zonas por intuición.





Portal Américas vs. Portal Norte

Portal Américas: 17.844 en madrugada / 39.794 en mañana.

Portal Norte: 5.023 / 34.379 respectivamente.

K-Means: eligiendo el número óptimo de grupos



K = 2

silueta máxima: 0,4009

El coeficiente de silueta compara la cohesión interna de cada grupo frente al grupo más cercano. Aunque la inercia (WCSS) sigue bajando con más grupos, K=2 ofrece la mejor separación relativa: una estructura útil pero moderada, no categorías naturales perfectas.

147 estaciones • 26 variables estandarizadas (StandardScaler): proporción de validaciones por hora, log del total y valor promedio.


Dos perfiles de estaciones, según intensidad de uso

Cluster	Estaciones	Mediana validaciones	Valor promedio mediano
0 — alta intensidad	75	5.582,00	2.978,43
1 — menor intensidad	72	2.718,33	3.343,86

Cluster 0: estaciones de alto volumen (Portal Américas, Portal Sur, Portal Suba, Portal Norte, Cabecera Usme).

Cluster 1: estaciones de menor intensidad (Calle 100, Calle 76, Restrepo, Avenida Chile).

El número del cluster es arbitrario — no implica "mejor" o "peor".



Lo que dicen los datos — y lo que no

Lecturas clave

- El uso está concentrado en el espacio (estaciones) y el tiempo (mañana).
- tullaave Plus y el perfil Adulto casi se determinan mutuamente en el registro.
- K-Means revela estructura de intensidad de uso, con separación moderada (silueta 0,40).
- PCA es solo una herramienta visual: la segmentación se hizo sobre 26 variables originales.

Limitaciones

- No hay variable geográfica de zona en las 19 columnas.
- La franja Noche (18-23h) tiene cero registros: limitación del dataset.
- El análisis es observacional y descriptivo, no causal.
- K-Means es no supervisado: no hubo modelo predictivo.
- El chi-cuadrado es muy sensible con más de un millón de registros; conviene acompañarlo de tamaño de efecto.

Próximos pasos para una segunda vuelta del proyecto

1

Incorporar una variable geográfica explícita (zona SITP o coordenadas).

2

Validar la cobertura temporal y documentar la ausencia de registros nocturnos.

3

Profundizar en el significado de las tarifas antes de detectar anomalías.

4

Complementar K-Means con otros métodos y comparar estabilidad de clusters.

5

Incluir métricas de tamaño de efecto junto a las pruebas de significancia.

6

Definir una variable objetivo y evaluar modelos supervisados a futuro.

CONCLUSIONES

Un ejercicio descriptivo, no causal — con hallazgos accionables

- Depuración necesaria y reproducible: -1.237 duplicados y 3 columnas vacías eliminadas.
- Portal Américas lidera con 62.331 validaciones; la franja Mañana concentra 69,24% del uso.
- tullave Plus (70,47%) y el perfil Adulto (50,08%) dominan las validaciones.
- La tarifa \$3.550 concentra la distribución de Valor; los "atípicos" de Tukey exigen lectura cuidadosa.
- K-Means (K=2, silueta 0,4009) y PCA (76,24% varianza) revelan dos perfiles claros de estación.